



Univerzitet u Novom Sadu
Fakultet tehničkih nauka



Dokumentacija za projektni zadatak
“Multi-agent reinforcement learning (DQN) za
dinamičku optimizaciju cena na tržištu
kratkoročnog iznajmljivanja”

Studenti: Milan Sazdov, SV21/2023
Lazar Sazdov, SV25/2023

Predmet: Osnovi računarske inteligencije

Tema projektnog zadatka: Multi-agent reinforcement learning (DQN) za dinamičku optimizaciju cena na tržištu kratkoročnog iznajmljivanja

Definicija problema

Na tržištima deljene ekonomije (sharing economy), poput platformi za kratkoročno izdavanje nekretnina, cene se često formiraju neefikasno jer se individualni akteri oslanjaju na statičke modele ili ličnu intuiciju, bez potpunog uvida u stanje tržišta. Uvođenjem algoritamskog određivanja cena otvara se novi, daleko ozbiljniji problem: kada više nezavisnih AI agenata/modela optimizuje cene u istom prostoru, one mogu naučiti da spontano sarađuju “*tacit collusion*”, veštački podižući cene iznad nivoa zdrave konkurencije bez direktne međusobne komunikacije.

Zašto je problem bitan za društvo i zašto ga vredi rešavati ?

Algoritamsko određivanje cena ubrzano preuzima kontrolu nad tržištima nekretnina, transporta i trgovine. Zbog toga je od kritične važnosti za društvo razumevanje da li nezavisni RL agenti prirodno konvergiraju ka konkurentnim tržišnim cenama (Nešov ekvilibrijum) ili ka monopolističkoj eksploataciji potrošača. Rešavanje ovog problema kroz simulaciju na realnim podacima omogućava nam da identifikujemo tranzicione tačke i tržišne uslove pod kojima algoritmi počinju da štete potrošačima formiranjem kartela.

Praktična primena i problemi koje rešenje otklanja

- **Regulatorna i antimonopolska kontrola:** Gradske uprave i regulatorna tela mogu koristiti ovakve simulatore tržišta kako bi detektovali algoritamsku manipulaciju cenama i predvideli ekonomske posledice pre nego što dozvole masovnu primenu "pametnih" algoritama za cene na svojim teritorijama.
- **Optimizacija Property Management Sistema (PMS):** Rešenje služi kao napredni backend modul “*Pricing Engine*” koji domaćinima automatski pronalazi optimalnu cenu, sprečavajući "trku do dna" (gde svi gube profit) ili prekomerno "naduvavanje" cena (nekretnine ostaju prazne).
- **Finansijski i osiguravajući sektor:** Arhitektura Multi-Agent DQN simulacije nije ograničena na nekretnine. Isti model dinamičkog određivanja cena direktno se prevodi u sisteme za prodaju polisa osiguranja i slično. Umesto oslanjanja na statičke tabele, backend sistem osiguranja može koristiti ovakvu arhitekturu da u realnom vremenu optimizuje cene premija na osnovu promenljivih faktora rizika i strategija konkurenata, maksimizujući konverziju uz očuvanje profitabilnosti.

Skup podataka

Temelj svake empirijski vođene analize u mašinskom učenju predstavlja kvalitet, obim i struktura raspoloživih opservacionih podataka. U sklopu ovog istraživanja koristi se otvoreni skup podataka *Inside Airbnb*, nezavisnog projekta posvećenog prikupljanju, obradi i analizi javno dostupnih informacija o kratkoročnom izdavanju nekretnina širom sveta. Ovaj skup obezbeđuje nivo granularnosti, kako na nivou pojedinačnog oglasa, tako i na nivou dnevne dostupnosti kroz čitavu godinu, koji je neophodan za precizno učenje modela uslovne verovatnoće rezervacije, na kome počiva celokupna simulaciona arhitektura projekta.

Izvor i licenca. Podaci su preuzeti sa zvaničnog repozitorijuma platforme *Inside Airbnb* (URL: <https://insideairbnb.com/get-the-data/>) i licencirani su pod uslovima *Creative Commons Attribution 4.0 International License (CC BY 4.0)*, čime su u potpunosti zadovoljeni akademski i etički standardi reproduktivnosti istraživanja. Struktura kolona i značenje svakog atributa dokumentovani su u zvaničnom *Data Dictionary* dokumentu platforme, koji je korišćen kao referenca tokom faze preprocesiranja.

Izbor tržišta i preseka.

Specifičan presek (*snapshot*) podataka koji se koristi u ovom radu datiran je na 14. septembar 2025. godine i odnosi se na područje grada Londona, Ujedinjeno Kraljevstvo. London je strateški izabran zbog nekoliko tržišnih faktora koji su direktno relevantni za predmet istraživanja:

- prisustva strogog zakonskog ograničenja od najviše 90 dana godišnje za kratkoročno izdavanje koje veštački ograničava ponude i pojačava konkurentski pritisak među domaćinima
- visokog udela domaćina koji upravljaju većim brojem oglasa (eng. multi-listing hosts), što predstavlja oblik de facto centralizovane kontrole cena nad više jedinica
- kao i činjenice da je reč o zrelom i gusto naseljenom tržištu na kome je primena softvera za algoritamsko određivanje cena u širokoj upotrebi.

Posebno je značajna visoka gustina oglasa po naselju, budući da definicija prostora stanja agenta počiva na K najbližih geografskih konkurenata mehanizam koji je smislen jedino na tržištu sa dovoljnim brojem prostorno bliskih, uporedivih oglasa.

Napomena o generalizabilnosti.

Izbor Londona i navedenog preseka je metodološke prirode i ne predstavlja suštinsko ograničenje pristupa. Predložena arhitektura ne zavisi ni od jednog svojstva specifičnog za London niti za odabrani datum: budući da svi gradovi i svi preseki u okviru projekta *Inside Airbnb* dele identičnu strukturu podataka (iste formate, kolone i attribute), prelazak na drugo tržište ili drugi vremenski presek svodi se na izmenu putanje do izvora podataka, bez ikakvih izmena u logici preprocesiranja, modelu potražnje ili simulacionom okruženju. Iz tog razloga, London i presek od 14. septembra 2025. godine predstavljaju primarni skup nad kojim se sistem razvija i evaluira, dok je tokom validacije predviđena i provera robusnosti rezultata na dodatnim tržištima (drugim gusto naseljenim turističkim gradovima) i, po potrebi, na drugim presecima. Cilj te provere jeste da se utvrdi u kojoj meri su uočene pojave opšte prirode, a ne posledica karakteristika jednog konkretnog tržišta.

Obim podataka i procena broja instanci.

Posmatrani presek londonskog tržišta obuhvata 96.871 jedinstveni oglas. Svaki oglas poseduje kalendar raspoloživosti za narednih 365 dana, skup podataka na nivou para (oglas, dan) sadrži 35.357.974 zapisa, što prelazi red veličine od više desetina miliona redova i zahteva primenu memorijski optimizovanih struktura i vektorskih operacija (biblioteke **pandas** i **NumPy**) već u fazi učitavanja i čišćenja. Od ukupnog broja oglasa, validnu i upotrebljivu vrednost cene poseduje 61.963 oglasa (približno 64%). Preostali oglasi, kod kojih cena nije zabeležena, isključuju se iz faze učenja modela potražnje, čime se kao radni uzorak zadržava i dalje statistički obiman skup od gotovo 62 hiljade oglasa.

Arhitektura podataka i ključni atributi.

Podaci se distribuiraju u kompresovanom obliku (CSV i GeoJSON). Za potrebe analize integrišu se četiri primarna izvora. Fajl **listings.csv.gz** predstavlja detaljan prikaz tehničkih, ekonomskih i reputacionih karakteristika svakog oglasa i ujedno je primarni izvor cene i ulaznih atributa za model potražnje (ključni atributi: *id*, *price*, *latitude*, *longitude*, *room_type*, *accommodates*, *minimum_nights*, *number_of_reviews*, *review_scores_rating*, *host_is_superhost*, *calculated_host_listings_count*). Fajl **calendar.csv.gz** sadrži vremensku seriju dnevne dostupnosti svakog oglasa kroz godinu i predstavlja primarni izvor signala o rezervisanosti i sezonalnosti (ključni atributi: *listing_id*, *date*, *available*). Fajl **neighbourhoods.geojson** koristi se za geoprostorno filtriranje i konstrukciju klastera konkurencije po naseljima (npr. *Westminster*, *Camden*, *Tower Hamlets*, *Hackney*), kroz poligone granica naselja i identifikatore geografskih regija. Konačno, fajl **reviews.csv.gz**, koji sadrži korisničke recenzije, koristi se za utvrđivanje aktivnosti oglasa, takođe je rezervisan za moguća buduća proširenja modela i ne koristi se u osnovnoj analizi.

calendar.csv služi kao izvor binarnog signala o dnevnoj dostupnosti. Logička vrednost *available* = false tretira se kao šumovit indikator rezervacije (*noisy booking proxy*), nedostupnost datuma ne implicira nužno ostvarenu rezervaciju, jer domaćin može i ručno blokirati termin. Ovo ograničenje eksplicitno se priznaje i ublažava ograničavanjem analize na aktivne oglase sa zabeleženom recenzijском aktivnošću, kod kojih je veza između nedostupnosti i stvarne rezervisanosti najpouzdanija.

Naziv	Sadržaj i primena	Ključni atributi
listings.csv.gz	Prikaz detaljnih tehničkih, ekonomskih i reputacionih karakteristika svakog jedinstvenog oglasa.	id, price (osnovna cena), room_type, accommodates, minimum_nights, review_scores_rating,
calendar.csv.gz	Vremenska serija dnevne dostupnosti i cenovnih fluktuacija usled sezonalnosti i manuelnog prilagođavanj	listing_id date available (boolean)
reviews.csv.gz	Skup ocena korisnika	
neighbourhoods.geojson	Geoprostorno filtriranje	Poligoni granica naselja, identifikatori geografskih regija.

Napomena o poreklu i potpunosti podataka

Svi podaci korišćeni u ovom radu potiču isključivo sa zvaničnog repozitorijuma projekta *Inside Airbnb*.

Ne koriste se nikakvi drugi izvori niti dopunski skupovi podataka.

S obzirom na to da kvalitet i potpunost javno objavljenih preseka variraju između gradova i vremenskih tačaka kako je i pokazano nepopunjenošću cenovnih kolona u kalendarskom fajlu posmatranog preseka zadržavamo mogućnost da, ukoliko tokom dalje obrade utvrdimo nedovoljnu potpunost ili upotrebljivost podataka, presek (*snapshot*) i/ili posmatrano područje zamenimo odgovarajućom alternativom.

Budući da svi preseki u okviru projekta *Inside Airbnb* dele identičnu strukturu, ovakva zamena ne bi zahtevala izmene u metodologiji, već isključivo u izvoru podataka, čime se očuvava doslednost celokupnog pristupa.

Metodologija

Sistem je dizajniran kroz arhitekturu od dva stuba (*Pillars*), čime eliminišemo rizik da RL agenti uče u nerealističnom okruženju, a istovremeno osiguravamo stabilnost konvergencije Multi-Agent sistema.

Centralni izazov ovog projekta jeste prividni paradoks. Da bismo proučavali kako se agenti ponašaju na tržištu, potrebno nam je okruženje u kome oni mogu da isprobaju proizvoljnu cenu i odmah vide ishod a to nije moguće nad sirovim istorijskim podacima, jer oni beleže samo ono što se jednom dogodilo, a ne i kako bi tržište reagovalo na cenu koja nikada nije postavljena. Upravo to rešava dvostubna arhitektura. Prvi stub iz realnih podataka uči model koji ume da predvidi ishod za bilo koju cenu, a drugi stub taj model koristi kao “mehaniku sveta” unutar koje agenti slobodno eksperimentišu. Tako agenti uče u okruženju ukorenjenom u stvarnosti, a mi istovremeno zadržavamo kontrolu da variramo tržišne uslove i ispitamo kada sistem klizi ka koluziji, a kada ka konkurenciji.

Faza 1: Modelovanje potražnje i simulacionog okruženja (*Supervised ML*)

Da bi simulacija bila legitimna, agenti ne smeju učiti u nasumičnom okruženju. Prvo gradimo nadgledani model mašinskog učenja (*Demand Model*) na osnovu istorijskih Airbnb podataka.

- **Cilj:** Učenje funkcije potražnje $P(\text{rezervacija} \mid \text{cena}, \text{kontekst})$, to jest verovatnoća da će listing biti rezervisan određenog dana.
- **Algoritmi:** Koristićemo Logističku regresiju (za postavljanje *baseline* modela i ekstrakciju cenovne elastičnosti) i *Multi-Layer Perceptron* (MLP) za nelinearno mapiranje kompleksnih zavisnosti (sezonalnost, recenzije, cene konkurenata).
- Ovaj istrenirani MLP model postaje "mehanika sveta" unutar našeg simulacionog okruženja (RL okruženja), određujući da li RL agenti dobijaju rezervaciju na osnovu cena koje postavе.

Faza 2: Formulacija Markovljevog procesa odlučivanja (MDP)

Unutar simuliranog tržišta, problem dinamičkog formiranja cena modelujemo kao Markovljevu igru za više agenata:

- **Stanje (State - S):** Vektor koji sadrži: trenutnu cenu agenta u odnosu na medijanu komšiluka, istorijsku popunjenost, faktor sezonalnosti i **skorašnje cene K najbližih konkurenata** (ključno za rešavanje problema nestacionarnosti u Multi-Agent sistemima).
- **Akcija (Action - A):** Diskretan prostor akcija potreban za DQN. Agent u svakom koraku bira modifikaciju cene: $\{-10\%, -5\%, \text{zadrži}, +5\%, +10\%\}$.
- **Nagrada (Reward - R):** Prihod po koraku (*cena $\times$ indikator rezervacije*).

Faza 3: Arhitektura Multi-Agent Deep Q-Networks (DQN)

Svaki listing na tržištu je nezavisan RL agent vođen sopstvenom neuronskom mrežom (Feed-Forward MLP).

- Mreža aproksimira Q-vrednosti za svaku moguću akciju, ažurirajući se prema Bellmanovoj jednačini:

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

- **Istraživanje prostora:** Agenti koriste epsilon-greedy strategiju sa opadajućim faktorom istraživanja, kako bi na početku eksplorisali različite cenovne strategije, a kasnije eksploatisali naučeno znanje.

Faza 4: Mehanizmi stabilizacije i Behavioral Cloning

Naivno postavljen, sistem iz prethodne faze pati od dva problema koja u višeagentskom okruženju mogu onemogućiti učenje:

1. **nestabilnosti** (mreža istovremeno uči i postavlja sopstvene ciljeve, uz jako korelisana uzastopna iskustva, pa učenje osciluje)
2. **sporog početka** (novoinicijalizovana mreža u prvim epizodama deluje nasumično i troši ogroman broj koraka pre nego što išta korisno nauči).

Kako bi se sprečilo da mreže osciliraju i da sistem degradira, implementiramo sledeće *State-of-the-Art* RL tehnike:

1. **Experience Replay Buffer:** Agenti čuvaju istoriju svojih interakcija (S, A, R, S') i treniraju neuronsku mrežu prikupljanjem nasumičnih *mini-batch* serija, čime razbijaju vremensku korelaciju podataka.
2. **Target Mreže:** Koristimo duplu arhitekturu neuronskih mreža (aktivna *Policy* mreža i zamrznuta *Target* mreža) kako bi ciljevi učenja ostali stabilni tokom propagacije greške (*Backpropagation*).
3. **Behavioral Cloning (Rešavanje "Cold-Start" problema):** Pre pokretanja RL-a, težine neuronskih mreža agenata ćemo inicijalizovati nadgledanim učenjem na istorijskim cenama pravih domaćina iz *calendar.csv* fajla. Time agenti započinju simulaciju sa "ljudskim" heuristikama, a RL proces služi samo da te strategije usavrši, drastično smanjujući vreme konvergencije.

Način evaluacije

S obzirom na dvostruku arhitekturu projekta, evaluacija se ne oslanja na jednostavne binarne metrike, već je podeljena u tri faze.

1. Evaluacija modela potražnje (Supervised ML):

S obzirom na to da prvi sloj projekta uči verovatnoću rezervacije $P(\text{rezervacija} \mid \text{cena}, \text{kontekst})$, standardna metrika tačnosti (Accuracy) je neadekvatna zbog disbalansa klasa (dani kada je listing prazan vs. dani kada je rezervisan). Metrike koje ćemo koristiti su:

- **Log-Loss (Cross-Entropy):** Glavna metrika za evaluaciju kvaliteta predviđene verovatnoće.
- **PR-AUC (Precision-Recall Area Under Curve):** Osetljivija i preciznija metrika od standardnog ROC-AUC za disbalansirane skupove podataka kakvi su kalendari rezervacija.
- **Krive kalibracije (Calibration Plots):** Najvažniji test za *Pricing Engine*. Proveravamo da li modelova predikcija od 70% verovatnoće zaista znači da se listing u realnosti rezerviše u 70% slučajeva pri toj ceni.

2. Evaluacija RL Agenata (Multi-Agent DQN):

Učenje uslovljavanjem se ne evaluira klasičnim greškama, već analizom ponašanja agenata unutar okruženja tokom vremena.

- **Kriva učenja (Learning Curves):** Vizuelizacija kumulativne nagrade (ostvarenog prihoda) po epizodi. Cilj je dokazati da se nagrada stabilizuje i maksimizuje kako vreme odmiče, dokazujući da RL konvergira.
- **Trajektorije cena (Price Convergence):** Grafički prikaz oscilacija cena koje agenti postavljaju kroz epizode. Uspešan trening rezultuje prelaskom iz haotičnog istraživanja (eksploracije) u stabilno stanje formiranja cena.

3. Teoretska i ekonomska evaluacija:

Da bismo dokazali da su agenti doneli **racionalne odluke**, njihove rezultate moramo uporediti sa apsolutnim referentnim vrednostima (*Baselines*):

- **Poređenje sa statičnim heuristikama:** Prihod koji DQN agenti ostvare upoređuje se sa prihodom "naivnih" agenata (npr. agent koji uvek drži prosečnu cenu komšiluka, ili agent koji nasumično menja cenu).
- **Analiza ekvilibrijuma (Monopol vs. Konkurencija):** Izračunaćemo dve teorijske granice; konkurentnu cenu i monopolističku cenu (gde agenti koordinisano određuju cene i maksimizuju zajednički profit). U finalnoj evaluaciji proveravamo gde su se RL agenti pozicionirali između ove dve granice. Ovo dokazuje da li su agenti naučili da se takmiče ili da formiraju algoritamski kartel (*tacit collusion*).

Tehnologije

Celokupan sistem se razvija u **Python 3.13+** programskom jeziku, uz korišćenje specijalizovanih biblioteka podeljenih u četiri kategorije. Kako proces obučavanja Multi-Agent sistema zahteva intenzivno paralelno procesiranje i optimizaciju memorije, izvršavanje i razvoj će se primarno raditi u lokalnom **Linux (Ubuntu)** okruženju (koristićemo i Windows), zbog veće stabilnosti i lakšeg podešavanja biblioteka za duboko učenje.

1. Okruženje za Reinforcement Learning simulaciju:

- **Gymnasium (Farama Foundation):** Industrijski standard (naslednik OpenAI Gym-a) za kreiranje *Markovljevih procesa odlučivanja (MDP)*. Koristi se za programiranje same tržišne simulacije, definisanje pravila igre, nagrada (rewards) i prostora akcija/stanja za agente.

2. Algoritmi Dubokog Učenja (RL i modelovanje potražnje):

- **PyTorch:** Primarni *Deep Learning* okvir. Koristi se za izgradnju *Multi-Layer Perceptron* (MLP) arhitektura, kao i za razvoj *Deep Q-Networks* (DQN) agenata. PyTorch je odabran zbog dinamičkih računskih grafova, što znatno olakšava debugovanje i paralelizaciju kod nestacionarnih *Multi-Agent* sistema u odnosu na TensorFlow.

3. Obrada podataka i Baseline modeli:

- **pandas i NumPy:** Za učitavanje kompresovanih `calendar.csv.gz` i `listings.csv.gz` fajlova, čišćenje nedostajućih vrednosti i vektorske operacije nad podacima.
- **scikit-learn:** Za kreiranje modela nadgledanog učenja iz *Faze I* (Logistička regresija), podelu skupa podataka (train/test split), kao i za izračunavanje evalucionih metrika (Log-Loss, PR-AUC, krive kalibracije).

4. Vizuelizacija i analiza rezultata:

- **matplotlib i seaborn:** Za generisanje analitičkih prikaza, *Learning Curves*, konvergencije cena tokom epizoda simulacije i pozicioniranja RL agenata u odnosu na *Nashov ekvilibrijum*.
- **Jupyter Notebook:** Za interaktivnu analizu podataka (Exploratory Data Analysis) u početnoj fazi, dok će se samo obučavanje modela i simulacija izvršavati kroz optimizovane .py skripte.

5. Google Colab:

- Koristićemo ga za fazu treniranja modela, jer omogućava GPU akceleraciju i brže obučavanje Multi-Agent DQN sistema.

Primeri

Dinamičko formiranje cena, koje u ovom projektu modelujemo kao MDP (Markovljev proces odlučivanja), čini osnovu komercijalnih softvera za optimizaciju cena (Pricing Engines) na tržištu kratkoročnog izdavanja. Da su algoritmi poput našeg primenljivi i traženi u praksi, najbolje pokazuju sledeća komercijalna rešenja:

1. **AirDNA (Platforma MarketMinder™):** Kao jedna od vodećih platformi za analizu podataka, AirDNA prati potražnju za preko 10 miliona objekata na platformama poput Airbnb-a i Vrbo-a još od 2015. godine. Njihov alat za pametno određivanje cena zasniva se na predviđanju popunjenosti na nivou mikro-lokacija. Slično pristupu koji planiramo u našem Stubu 1, njihov algoritam detaljno analizira lokalne faktore (poput sezonalnosti i uticaja okruženja) kako bi vlasnicima ponudio preporučene cene. U praksi, ovo često dovodi do ujednačavanja cena u čitavim naseljima.
URL: <https://www.airdna.co/pricing>
2. **PriceLabs:** Ova platforma se ističe po visoko automatizovanom i proaktivnom pristupu dinamičkom formiranju cena. Njen sistem automatski prilagođava last-minute popuste i podiže cene za događaje u daljoj budućnosti, oslanjajući se na kombinaciju unapred definisanih pravila i mašinskog učenja. PriceLabs u realnom vremenu analizira konkurenciju i upravlja restrikcijama poput minimalnog broja noćenja, što je direktno uporedivo sa parametrima MDP prostora stanja koje definišemo u našem Stubu 2. Pored toga, nudi upravljanje čitavim portfolijima objekata istovremeno, što daje veliku prednost institucionalnim investitorima.
URL: <https://hello.pricelabs.co/dynamic-pricing/>
3. **Beyond (ranije BeyondPricing):** Kao jedan od pionira na tržištu, ovaj alat svakodnevno analizira milijarde podataka kako bi za svaki dan odredio optimalnu cenu. Za razliku od platformi poput PriceLabs-a, koje se oslanjaju na fleksibilno definisanje pravila (poput minimalnog broja noćenja), Beyond se fokusira na potpunu automatizaciju. Njihov sistem vrši autonomno ažuriranje cena putem API-ja, bez potrebe za naknadnom ljudskom potvrdom, naplaćujući proviziju od oko 1% na ostvareni prihod. Beyond u praksi koristi algoritme vrlo slične onima koje predlažemo u ovom projektu i, prema njihovim podacima, povećava broj rezervacija za 21%. Ovo jasno potvrđuje sposobnost AI modela da nadmaše i potisnu individualne domaćine na tržištu kratkoročnog izdavanja.
URL: <https://beyondpricing.com/>

Relevantna literatura

1. **Calvano, E., Calzolari, G., Denicolò, V., & Pastorello, S. (2020).** *Artificial Intelligence, Algorithms, and Collusion*. American Economic Review, 110(10), 3267–3297.
<https://doi.org/10.1257/aer.20190623>
2. **Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G.,... & Hassabis, D. (2015).** *Human-level control through deep reinforcement learning*. Nature, 518(7540), 529–533. <https://www.nature.com/articles/nature14236>
3. **Sutton, R. S., & Barto, A. G. (2018).** *Reinforcement Learning: An Introduction (2nd ed.)*. MIT Press. <https://web.stanford.edu/class/psych209/Readings/SuttonBartoIPRLBook2ndEd.pdf>
4. **Russell, S., & Norvig, P. (2020).** *Artificial Intelligence: A Modern Approach (4th ed.)* (Preporučena literatura predmeta)
5. **dr Predrag Janičić, dr Mladen Nikolić “Veštačka inteligencija”, Matematički fakultet Univerziteta u Beogradu.** https://poincare.matf.bg.ac.rs/~predrag.janicic/books/VI_B5.pdf
6. **McFadden, D. (1974).** *Conditional logit analysis of qualitative choice behavior*. In P. Zarembka (Ed.), *Frontiers in Econometrics* (pp. 105–142). Academic Press.
<https://eml.berkeley.edu/reprints/mcfadden/zarembka.pdf>
7. **Inside Airbnb.** *Get the Data and Data Dictionary*. <https://insideairbnb.com/get-the-data/>
8. **Farama Foundation. (2024).** *Gymnasium: A standard API for reinforcement learning*.
<https://github.com/Farama-Foundation/Gymnasium>
9. **Assad, S., Clark, R., Ershov, D., & Xu, L. (2024).** *Algorithmic Pricing and Competition: Empirical Evidence from the German Retail Gasoline Market*. Journal of Political Economy, 132(3), 723–771. <https://www.journals.uchicago.edu/doi/10.1086/726906>
10. **Deng, S., et al. (2024).** *Algorithmic Collusion in Dynamic Pricing with Deep Reinforcement Learning*. arXiv preprint arXiv:2406.02437. <https://doi.org/10.48550/arXiv.2406.02437>
11. **Tinoco, S., et al. (2025).** *Impact of Price Inflation on Algorithmic Collusion Through Reinforcement Learning Agents*. arXiv preprint arXiv:2504.05335.
<https://doi.org/10.48550/arXiv.2504.05335>
12. **Paszke, A., et al. (2019).** *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. Advances in Neural Information Processing Systems 32, 8024–8035.
<https://proceedings.neurips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library.pdf>