

Univerzitet u Novom Sadu

Fakultet tehničkih nauka

Rezultati projektnog zadatka

“Multi-agent reinforcement learning (DQN) za dinamičku optimizaciju
cena na tržištu kratkoročnog iznajmljivanja”

Studenti: Milan Sazdov, SV21/2023
Lazar Sazdov, SV25/2023

Predmet: Osnovi računarske inteligencije

Tema projektnog zadatka: Multi-agent reinforcement learning (DQN) za dinamičku optimizaciju cena na tržištu kratkoročnog iznajmljivanja

Sadržaj

1	Uvod i cilj istraživanja	2
2	Skup podataka i pretprocesiranje	2
2.1	Preseci i ključno otkriće o cenama	2
2.2	Oznaka rezervacije: razlika dva preseka	3
2.3	Kontrola šuma i obim skupa	3
3	Prvi stub: model potražnje	5
3.1	Izbor modela i zašto baš takav	5
3.2	Strukturna korekcija elastičnosti	6
4	Drugi stub: simulaciono okruženje i agenti	6
4.1	Tržište kao Markovljeva igra	6
4.2	Agenti i zašto baš takvi	7
4.3	Granice ekvilibrijuma i osnovne politike	7
5	Eksperimentalna postavka	8
6	Rezultati	8
6.1	Indeks dobiti po eksperimentima	8
6.2	H1: DQN agenti se ne dogovaraju	9
6.3	H2: algoritam presudno određuje ishod, PPO deli tržište	10
6.4	H3: formalni test na Δ ovde nije upotrebljiv	12
6.5	E5: inflacija nije signal za koordinaciju	13
6.6	E6: da li bi drugačija podešavanja promenila zaključak?	13
7	Diskusija	14
8	Ograničenja	15
9	Zaključak	15

1 Uvod i cilj istraživanja

Algoritamsko određivanje cena ubrzano preuzima kontrolu nad tržištima kratkoročnog iznajmljivanja nekretnina. Kada više nezavisnih agenata, vođenih algoritmima mašinskog učenja, optimizuje cene u istom prostoru, postoji rizik da nauče da spontano sarađuju (*tacit collusion*), veštački podižući cene iznad nivoa zdrave konkurencije bez ikakve međusobne komunikacije. Centralna hipoteza projekta glasi da nezavisni agenti bazirani na Deep Q-Network algoritmu, usled ponavljane interakcije u zajedničkom Markovljevom procesu odlučivanja, prirodno konvergiraju ka cenama iznad konkurentskog nivoa.

Sistem je realizovan kroz dvostubnu arhitekturu predviđenu specifikacijom: prvi stub iz realnih *Inside Airbnb* podataka uči nadgledani model potražnje $P(\text{rezervacija} \mid \text{cena}, \text{kontekst})$, a drugi stub taj model koristi kao “mehaniku sveta” unutar PettingZoo simulacije u kojoj svaki oglas predstavlja nezavisnog RL agenta. Nivo koluzije se kvantifikuje indeksom dobiti (*Profit Gain Index*):

$$\Delta = \frac{\pi_{\text{RL}} - \pi_{\text{N}}}{\pi_{\text{M}} - \pi_{\text{N}}}, \quad (1)$$

gde je π_{N} profit u Nešovom ekvilibrijumu, a π_{M} monopolski (kartelski) profit, obe granice izračunate empirijski na stvarnom simuliranom tržištu. Vrednost $\Delta = 0$ odgovara konkurentnom ponašanju, $\Delta = 1$ punom kartelu.

Formalne hipoteze glase:

- **H1:** DQN agenti u simulaciji dostižu $\Delta > 0.15$ nakon 500,000 koraka (jednosmerni t-test, $p < 0.05$, 20 nezavisnih ponavljanja).
- **H2:** nivo koluzije zavisi od izbora algoritma: TQL, DQN i PPO pri identičnim tržišnim uslovima dostižu statistički različite vrednosti Δ . Kao dopunska provera testira se i smer koji literatura očekuje (TQL iznad DQN-a, DQN iznad PPO-a).
- **H3:** prosečni Δ sa četiri agenta je niži od Δ sa dva agenta, pri identičnom algoritmu.

Važno je istaći da su oba ishoda H1 naučno upotrebljiva: potvrda bi značila da realno tržište spontano klizi ka kartelu, a odbacivanje da automatske koluzije nema, što je nalaz sa direktnom regulatornom vrednošću. Rezultati će pokazati ovo drugo, kao i da izbor algoritma, koliko i samo tržište, određuje da li se dogovaranje uopšte javlja.

Projekat je organizovan tako da sva logika živi u Python paketu (`src/airbnb_marl`) i parametrizovanim skriptama, dok su Jupyter sveske namerno tanke: pozivaju kod iz paketa, prikazuju rezultate i sadrže kratka objašnjenja pre i zaključke posle svake ćelije. Svi eksperimenti su definisani YAML konfiguracijama, a rezultati svakog ponavljanja (*seed*) se automatski verzionišu, čime je obezbeđena puna reproduktivnost.

2 Skup podataka i pretprocesiranje

2.1 Preseci i ključno otkriće o cenama


Korišćeni su isključivo javni podaci projekta *Inside Airbnb* za London. Specifikacija je imenovala presek od 14. septembra 2025. godine i eksplicitno dozvolila zamenu preseka ukoliko se pokaže nepotpunim. Upravo se to dogodilo: provera je pokazala da kalendarski fajl preseka 2025-09-14 sadrži cenovne kolone koje su **prazne u svih 35.357.974 redova**, dok su noviji preseci te kolone potpuno izbacili. Svaki oglas i dalje nosi svoju realnu izlistanu cenu noćenja (`listings.csv`), i ona je cenovni signal kroz ceo projekat; ono što ne postoji ni u jednom dostupnom preseku jeste *dnevna istorija cena*. Posledice su dve: kloniranje ponašanja (*behavioral cloning*) nad istorijskim promenama cena je nemoguće, a cenovni signal za model potražnje je isključivo poprečnog preseka (*cross-sectional*).

Zbog toga su korišćena četiri preseka koja formiraju dva vremenska para: letnji (2026-05-24 → 2026-06-19, primarni) i jesenji (2025-09-14 → 2025-10-17).

2.2 Oznaka rezervacije: razlika dva preseka

Logička vrednost `available = false` sama po sebi nije oznaka rezervacije, jer domaćin može i ručno blokirati datum. Umesto toga, oznaka je definisana kao **razlika dva preseka**: noć koja je bila otvorena u trenutku t_0 a nedostupna u trenutku t_1 smatra se rezervisanom unutar prozora od oko 26 dana. Noći već zatvorene u t_0 ne nose signal potražnje pri posmatranoj ceni i isključene su. Sidrenje oznaka preko recenzija na dnevnom nivou načelno je nemoguće, jer recenzije prestaju na datum preseka a kalendar tada počinje, pa recenzije služe kao filter aktivnosti oglasa i kontrola obima.


Dva sezonski različita para su neophodna iz statističkog razloga: unutar jednog para, vreme do dolaska (*lead time*) i datum boravka su savršeno kolinearni, pa model ne bi mogao da razdvoji sezonalnost od opadanja verovatnoće sa udaljenošću datuma. Slika 1 pokazuje da se opadanje sa *lead*-om replicira u oba para, dok se isti meseci boravka pojavljuju na različitim udaljenostima, čime postaju razdvojivi.



Slika 1: Verovatnoća rezervacije u funkciji vremena do dolaska (levo) i meseca boravka (desno), po sezonskim parovima. Preklapanje meseci na različitim *lead* vrednostima omogućava razdvajanje ta dva efekta.


2.3 Kontrola šuma i obim skupa

Deo nedostupnih noći potiče od blokada domaćina, ne od rezervacija. Primenjene su tri kontrole: (1) oglasi čiji se ceo otvoreni kalendar preokrenuo (pauzirani profili) uklonjeni su, oko 1% po paru; (2) analiza dužina uzastopnih “rezervisanih” nizova (slika 2) pokazuje medijanu od oko 3 noći, što odgovara realnim boravcima, dok oko 20 do 25% noći leži u nizovima dužim od 28 noći i verovatno predstavlja blokade; taj udeo se navodi kao gornja granica šuma oznake; (3) analiza je ograničena na aktivne oglase sa skorašnjom recenzijskom aktivnošću.



Slika 2: Raspodela dužina uzastopnih rezervisanih nizova. Kratki nizovi odgovaraju realnim boravcima; dugi nizovi su verovatno blokade domaćina i kvantifikuju šum oznake.

Konačan skup sadrži **7.155.606 označenih noći** sa ukupnom stopom rezervacije od 13.7% (13.2% letnji, 14.1% jesenji par), nad 29.984 aktivnih oglasa od 92.638 sirovih. Podela na trening, validaciju i test je hronološka (70/15/15) unutar svakog para, čime se sprečava curenje budućih informacija u trening.



Slika 3: Raspodela izlistanih cena po tipu smeštaja (logaritamska skala). Teški desni rep motivirše ograničenje cena po paru pri pretprocesiranju.

Konkurentski klasteri su definisani kao 5 geografski najbližih oglasa istog tipa smeštaja i sličnog kapaciteta (± 1 osoba), što je smisleno pri londonskoj gustini: medijalna udaljenost do petog konkurenta je ispod jednog kilometra. Westminster, kao naselje sa najvećom gustinom uporedivih oglasa, definiše simulirano tržište.

3 Prvi stub: model potražnje


3.1 Izbor modela i zašto baš takav

Tri modela su poređena na netaknutoj hronološkoj test particiji: logistička regresija kao interpretabilna osnova i provera cenovne elastičnosti, LightGBM kao dijagnostički plafon skupa atributa, i višeslojni perceptron (MLP) kao primarni model. Ključna odluka je da MLP ostaje primarni model *iako* LightGBM postiže viši PR-AUC (tabela 1): stabla odlučivanja daju deo-po-deo konstantan odziv na cenu, što je loša površina za optimizaciju prihoda u simulaciji, dok glatki MLP daje kontinualan gradijent po ceni. Jaz između ta dva modela se transparentno navodi.

Tabela 1: Metrike na test particiji (prevalenca, tj. udeo pozitivnih primera: 0.0475). PR-AUC je površina ispod krive preciznost–odziv, Brier srednja kvadratna greška verovatnoća, ECE očekivana greška kalibracije. Tačnost (*accuracy*) se namerno ne prijavljuje jer je pri ovako disbalansiranim klasama dezinformativna.

Model	Log-Loss	PR-AUC	Brier	ECE
Logistička regresija	0.1915	0.0611	0.0453	0.0160
LightGBM (dijagnostika)	0.1701	0.2671	0.0411	0.0345
MLP (primarni)	0.1795	0.1564	0.0437	0.0156

Model je treniran nebalansiranom binarnom unakrsnom entropijom, svesno odstupajući od uobičajene prakse pondera klasa: pošto verovatnoće ovog modela postaju fizika simulacije, kalibracija je važnija od odziva (*recall*), a ponderisanje klasa sistematski iskrivljuje predviđene verovatnoće. Rezultat je ECE (*Expected Calibration Error*, prosečno odstupanje predviđene verovatnoće od stvarne učestanosti rezervacija) od svega 0.0156 bez potrebe za naknadnom kalibracijom (slika 4); PR-AUC je 3.3 puta iznad prevalencije. Standardizovani koeficijent relativne cene u logističkoj regresiji iznosi -0.163 , što potvrđuje očekivani negativni smer cenovne elastičnosti.




Slika 4: Dijagram pouzdanosti na test particiji. Tačke na dijagonali znače da su predviđene verovatnoće verne empirijskim učestanostima, što je uslov da simulacija ima naučnu vrednost.

3.2 Strukturna korekcija elastičnosti

Cenovni signal poprečnog preseka potcenjuje kauzalni odziv potražnje: skuplji stanovi su obično i kvalitetniji stanovi, pa se uticaj cene meša sa uticajem kvaliteta i sirova kriva prihoda dostizala maksimum na samoj gornjoj granici cena od $2.5 \times$ medijane, što bi simulaciju degenerisalo u agente prikovane za plafon. Zato se u simulaciji primenjuje strukturna korekcija

$$P_{\text{sim}}(r) = P_{\text{model}}(r) \cdot e^{\beta(r-1)}, \quad \beta = -0.425, \quad (2)$$

kalibrisana tako da maksimum prihoda padne na unutrašnji odnos cena od oko 1.1, što odgovara pretpostavci da domaćini u proseku već formiraju cene blizu sopstvenog optimuma. Važan izbor je eksponencijalni oblik: stepena korekcija r^b na ovim podacima ne može da proizvede unutrašnji maksimum, dok eksponencijalni oblik odgovara logit potražnji kod koje elastičnost raste sa cenom, kao u referentnoj literaturi. Artefakt čuvaju tri kapije koje moraju proći pre RL faze: PR-AUC iznad 1.5 prevalence (izmereno 3.3), monotonost po ceni i unutrašnji maksimum prihoda (izmereno 1.1); sve tri su prošle.



Slika 5: Kriva potražnje (levo) i implicirani prihod (desno), sirovi model naspram simulacione korekcije. Bez korekcije bi maksimum prihoda ležao na granici cena; korigovana kriva ima unutrašnji maksimum na odnosu 1.1.

4 Drugi stub: simulaciono okruženje i agenti

4.1 Tržište kao Markovljeva igra

Okruženje je implementirano kao PettingZoo `ParallelEnv`, pošto je istovremeno postavljanje cena po svojoj prirodi višeagentski problem koji jednoagentski Gymnasium interfejs ne opisuje; teži okviri poput RLlib-a su izbegnuti da bi lokalne mašine i Google Colab delili jednu malu, lako proverljivu putanju koda. Ključne odluke dizajna:

- **Stanje:** sopstvena cena u odnosu na medijanu tržišta, skorašnja popunjenost, kodirana sezonalnost i cene konkurenata iz *prethodnog* koraka. Kašnjenje od jednog koraka razrešava cirkularnost simultanih akcija: agent ne može posmatrati tuđu današnju cenu dok je i sam bira.
- **Akcije:** diskretna promena cene iz skupa $\{-10\%, -5\%, 0, +5\%, +10\%\}$, uz cene ograničene na $[0.5, 2.5] \times$ medijane klastera (pogoci granica se beleže).
- **Nagrada:** ostvareni prihod od rezervacije normalizovan osnovnom cenom oglasa, čime heterogeni oglasi dobijaju uporedive skale Q-vrednosti (Q-vrednost je agentova procena očekivane buduće zarade za pojedinačnu akciju). Rezervacija se izvlači iz verovatnoće modela potražnje.

- **Epizoda:** 365 dana; 500,000 koraka obuke po ponavljanju odgovara 1.370 epizoda. Kraj epizode je vremensko ograničenje, pa se ciljevi učenja propagiraju kroz njega (tretman skraćena po Pardo et al.).

Oba simulirana tržišta su realna: najgušće kompatibilne grupe oglasa u Westminsteru. Tržište sa četiri agenta je kolocirani blok gotovo identičnih oglasa koji u stvarnosti vodi jedan profesionalni domaćin, upravo onaj oblik koncentracije višestrukih oglasa koji specifikacija ističe kao de facto centralizovanu kontrolu cena. E2 je zato namerno postavljen kao *kontrafaktualni* eksperiment: pitamo šta bi se dogodilo kada bi ovakve, gotovo identične jedinice vodila četiri nezavisna algoritma, scenario koji nastaje čim se vlasništvo usitni a alati za cene postanu dostupni svakome. Nezavisnost agenata je, dakle, eksperimentalni tretman kojim se ispituje efekat broja konkurenata, a ne tvrdnja o današnjem vlasniku.

4.2 Agenti i zašto baš takvi

Primarni agent je **D3QN**: Double DQN suzbija precenjivanje Q-vrednosti koje nestacionarnost nezavisnog učenja dodatno pojačava, a Dueling arhitektura razdvaja vrednost stanja od prednosti akcija, korisno kada susedne cenovne akcije imaju gotovo identične vrednosti; oba dodatka su jeftina nadogradnja specifikiranog DQN-a. Stabilizacija koristi bafer iskustva (100k) i zamrznutu ciljnu mrežu. Umesto nemogućeg kloniranja istorijskih promena cena, mreže se inicijalizuju kloniranjem *sidrišne politike* (vraćanje ka izlistanoj ceni), što je opaživi deo realnog ponašanja domaćina i rešava problem hladnog starta.

PPO je minimalna sopstvena implementacija (isecena zamena cilja i GAE, generalizovana procena prednosti, oko 200 linija) umesto Stable-Baselines3: SB3 ne pokreće nativno PettingZoo višeagentske petlje, a slojevi omotača bi razdvojili putanju koda koju ostali agenti dele. TQL sa diskretizovanim stanjem služi kao most ka Calvano literaturi; kao primarni metod nije održiv jer realističan prostor stanja prevazilazi tabelarno nabranje.

4.3 Granice ekvilibrijuma i osnovne politike

Nešova granica se računa **iterativnim najboljim odgovorima** do fiksne tačke: jedan prolaz optimizacije, kako sugerišu prateći materijali, nije ekvilibrijum i potcenjuje Nešov profit. Monopolska granica maksimizuje zajednički profit koordinatnim usponom iz više početnih tačaka. Obe granice koriste isti model potražnje i istu normalizaciju nagrade kao obuka, pa je Δ interno konzistentan; analitičke granice iz literature ovde nisu dostupne jer je potražnja naučeni model bez zatvorene forme. Za tržište sa dva agenta: Nešov profit 0.4214 po agentu i koraku (odnosi cena 1.075 i 1.55), monopolski 0.4957 (odnosi 2.5 i 1.125, asimetričan optimum u kome jedan oglas žrtvuje potražnju na plafonu cena dok je drugi ubira). Statičke osnovne politike leže ispod Neša: sidrišna 0.3153, nasumična 0.2976, praćenje medijane 0.2642, što potvrđuje smislenost skale.

5 Eksperimentalna postavka

Tabela 2: Mreža eksperimenata. Svaki se izvršava sa 20 nezavisnih ponavljanja (seeds 42–61) po 500,000 koraka, ukupno 120 kompletnih obuka.

Eksperiment	Algoritam	Tržište	Uloga
E1	D3QN	2 agenta	primarni test koluzije (H1)
E2	D3QN	4 agenta	efekat broja agenata (H3)
E3	PPO	2 agenta	ablacija algoritma (H2)
E4	TQL	2 agenta	most ka Calvano literaturi (H2)
E5	D3QN + inflacija 10%/god.	2 agenta	robusnost, replikacija Tinoco
E6	D3QN, podešavanja naklonjena koluziji	2 agenta	robusnost H1 zaključka


Δ se računa nad poslednjom trećinom obuke (konvencija literature; uključuje eksploraciju $\varepsilon = 0.05$, tj. pet procenata nasumičnih poteza, i šum uzorkovanja rezervacija), a dopunski i nad čisto pohlepnom evaluacionom epizodom (bez nasumičnih poteza: agent uvek bira akciju sa najvećom procenom). Rezultati se prijavljuju kao raspodele preko 20 ponavljanja, jer je nezavisno Q-učenje nestacionarno po konstrukciji pa pojedinačne obuke nisu reprezentativne.

6 Rezultati

6.1 Indeks dobiti po eksperimentima

Tabela 3: Konačni rezultati (20 ponavljanja po eksperimentu).


Eksp.	Postavka	$\bar{\Delta}$	std	prosečna cena / medijana
E1	DQN, $N=2$	−0.77	0.08	1.11
E2	DQN, $N=4$	−1.23	0.17	1.84
E3	PPO, $N=2$	+ 0.27	0.13	1.61
E4	TQL, $N=2$	−1.26	0.22	1.07
E5	DQN, $N=2$, inflacija	−1.00	0.08	1.12
E6	DQN, $N=2$, ablacija	−0.99	0.19	1.09



Slika 6: Raspodela indeksa dobiti po eksperimentima, sa referentnim linijama za Neš (0), monopol (1) i prag H1 (0.15). E3 je jedina raspodela iznad nule i iznad praga koluzije; ablacija E6 ostaje u istoj zoni kao E1 i E5.


6.2 H1: DQN agenti se ne dogovaraju

Jednosmerni t-test daje $t = -51.7$, $p = 1.0$: nulta hipoteza se ne odbacuje i **H1 nije podržana**. D3QN parovi se smiruju blizu svoje sidrišne cene (odnos oko 1.1 medijane) i zarađuju ispod Nešovog profita, iako pobeđuju svaku statičku osnovu (0.364 naspram 0.315 za sidrišnu i 0.298 za nasumičnu politiku). Učenje dakle funkcioniše; režim cena iznad konkurentskog nivoa se ne pronade u okviru budžeta od 500,000 koraka. Važan strukturni nalaz objašnjava zašto kriva učenja (slika 7) ostaje i ispod Neša: Nešov ekvilibrijum ovog tržišta je asimetričan, a nijedan *simetričan* profil cena ne zarađuje više od oko 0.418. Dva identična nezavisna učenika nemaju mehanizam da naruše simetriju, pa im je i sam Nešov nivo nedostizhan.



Slika 7: E1: prosečan profit po agentu i koraku (20 ponavljanja, osenčen pojas je jedna standardna devijacija). Plato ostaje ispod Nešove granice.


Isto pokazuje i mapa zajedničkih akcija (slika 8): masa je koncentrisana u ekstremnim potezima, sa najčešćom ćelijom uzajamnog spuštanja cena, dok bi koluzivni par dominantno sedeo u ćeliji zadržavanja cena. Dinamika E1 je kruženje i konkurencija, ne prećutni dogovor.



Slika 8: E1: učestanost parova istovremenih akcija u pohlepnoj evaluaciji svih 20 ponavljanja. Dominiraju uglovi (sinhronizovana spuštanja i podizanja), a ne stabilno zadržavanje.


6.3 H2: algoritam presudno određuje ishod, PPO deli tržište

H2 je potvrđena: Kruskal–Wallis test preko tri algoritma daje $H = 51.2$, $p = 7.7 \times 10^{-12}$, a i sva tri parna poređenja su zasebno značajna (dvostrani Mann–Whitney, $p < 3 \times 10^{-7}$). Izbor algoritma, dakle, presudno određuje ishod na istom tržištu. Smer, međutim, nije onaj koji literatura očekuje: opaženi redosled je $PPO > DQN > TQL$, sa gotovo savršenom separacijom suprotno očekivanju ($U = 0$ odnosno $U = 10$ od 400 u smeru literature). TQL jedva prevazilazi sidrišnu osnovu (profit 0.327, odnos cena 1.07); 500,000 koraka je daleko ispod horizonta konvergencije tabularne literature, koja koristi milione epizoda, pa je nizak Δ TQL-a nalaz o budžetu, ne dokaz protiv Calvano rezultata (slika 9).




Slika 9: E4: TQL prvo uništi razumni sidrišni start eksploracijom nad grubim diskretizovanim stanjem, zatim se sporo oporavlja do nivoa jedva iznad osnovne politike.

Najupečatljiviji nalaz projekta je E3. PPO parovi dostižu $\Delta = +0.27$, iznad praga koji je H1 postavila za koluziju, i jedini prelaze Nešovu granicu (slika 10). Mehanizam je vidljiv u trajektoriji cena (slika 11): jedan agent se stepenasto penje do plafona cena i ostaje na njemu, dok drugi ostaje nisko i ciklusima podbija i ubira potražnju. To je tzv. Edgeworthov ciklus iz teorije oligopola: postepeno podbijanje cena praćeno naglim sinhronizovanim skokom naviše. Par time reprodukuje asimetričnu strukturu izračunatog monopolskog optimuma bez ikakve komunikacije: profit iznad konkurentskog nivoa potiče od **podele tržišta**, ne od simetričnog podizanja cena.



Slika 10: E3: PPO je jedini algoritam čija prosečna kriva prelazi Nešovu granicu; gornja ivica pojasa doseže blizu monopola.



Slika 11: E3, pohlepna evaluacija prvog ponavljanja: podela uloga. Agent 1 se penje do plafona i ne silazi; agent 0 podbija ispod njega u ciklusima.

Zašto baš PPO? Tri mehanizma se stiču: (1) stohastička politika prirodno narušava simetriju, a gradijent politike pojačava svaku slučajnu asimetriju koja se isplati; (2) učenje na sopstvenoj tekućoj politici (*on-policy*) prati aktuelno ponašanje rivala, dok DQN-ov bafer iskustva usrednjava mesece zastarelih strategija protivnika; (3) uzorkovana politika može glatko da se koncentriše i *zadrži* pronađenu konfiguraciju, dok striktno pohlepna politika (uvek bira akciju sa najvećom procenom) skače pri svakoj fluktuaciji Q-procena, a trajni $\varepsilon = 0.05$ neprestano remeti svaki pokušaj koordinacije. Dopunska pohlepna evaluacija iz odeljka 5 ovo direktno potvrđuje: kada se naučena stohastička politika projektuje na striktno pohlepnu, Δ za E3 pada sa $+0.27$ na -0.15 (uz veliko rasipanje, jer potiče iz jedne epizode po ponavljanju). To nije protivrečnost nego potvrda mehanizma (3): podelu tržišta održava upravo stohastičnost politike, pa njeno uklanjanje ruši koordinaciju.


6.4 H3: formalni test na Δ ovde nije upotrebljiv

Mann–Whitney test na vrednostima Δ formalno daje $p = 3.9 \times 10^{-8}$ u smeru H3, ali taj broj namerno ne proglašavamo potvrdom hipoteze, iz dva razloga. Prvo, granice za tržište sa četiri agenta su degenerisane i Δ za E2 ne meri koluziju. To tržište je blok gotovo identičnih oglasa jednog domaćina; apsolutni cenovni odziv modela za te oglase je gotovo ravan, a strukturna korekcija kažnjava samo relativni odnos cena prema rivalima, pa zajedničko podizanje cena gotovo ništa ne košta niti se duboka podbijanja isplate. Iterativni najbolji odgovori zato završavaju na plafonu cena za sva četiri agenta: Nešov profit 0.883 na odnosu 2.5, monopolski 0.995, raspon od svega 0.11 iznad svega dostižnog u unutrašnjosti. E2 agenti na 1.84 medijane zarađuju 0.744 i dobijaju $\Delta = -1.23$ *po konstrukciji*, pa test poredi meru koja na jednom od dva tržišta ne meri ono što hipoteza tvrdi.

Drugo, dva tržišta se ne razlikuju samo po broju agenata nego i po obliku potražnje, pa ni zamena metrike ne pomaže: profit izražen kao udeo Nešovog profita daje prednost E1 ($p = 0.002$), a isti profit izražen kao udeo monopolskog daje prednost E2 ($p = 0.99$). Ista sirova brojka, dve normalizacije, dva suprotna zaključka: ovakav dizajn, sa realnim i međusobno različitim tržištima, ne dozvoljava čistu formalnu presudu, i **H3 ostaje otvorena**.

Kvalitativna slika je pri tome saglasna sa teorijom oligopola: četiri agenta se kreću u labavoj sinhronizaciji, sa kolektivnim ratom cena sredinom godine (slika 12), i ne dostižu ni zajednički

optimum koji je u njihovom tržištu trivijalno isplativ. To navodimo kao opažanje, ne kao statistički dokaz. Zanimljiv je i kontrast sa stvarnošću: realni vlasnik ovog bloka problem koordinacije rešava vlasništvom, jednim centralizovanim cenovnikom za sve četiri jedinice, dok četiri nezavisna algoritma tu koordinaciju nisu uspela da reprodukuju.



Slika 12: E2, pohlepna evaluacija: kolektivno penjanje, dubok zajednički rat cena, oporavak. Obratiti pažnju na obrnute referentne linije, vizuelni potpis degenerisanih granica ovog tržišta.

Dublji uzrok zaslužuje isticanje: identifikacija cenovnog odziva iz poprečnog preseka potcenjuje *agregatnu* (tržišnu) elastičnost. Korekcija vraća sopstvenu elastičnost u odnosu na rivale, ali ostavlja tržišnu potražnju gotovo fiksnom, što ograničava koliko istovremeno podizanje cena uopšte može da šteti, a u homogenim klasterima uklanja i podsticaj za preotimanje potražnje.

6.5 E5: inflacija nije signal za koordinaciju


Pod inflacijom od 10% godišnje agenti pokazuju isto ponašanje kao u E1, bez znakova dogovaranja, na istim relativnim cenama (odnos 1.12), uz niži Δ (-1.00 naspram -0.77) jer fiksno nominalno formiranje cena gubi realnu vrednost naspram rastuće referentne potražnje. Nema dokaza da inflacija ovde deluje kao prećutni signal za sinhronizovano podizanje cena, što je suprotno zabrinutostima iz replicirane studije.

6.6 E6: da li bi drugačija podešavanja promenila zaključak?

Najočigledniji prigovor rezultatu H1 glasi: možda agenti ne sarađuju samo zato što su hiperparametri tako izabrani. Ablacija E6 proverava upravo to: ponavlja E1 sa tri izmene za koje je u tabularnoj literaturi poznato da pomažu nastanku koluzije: faktor diskontovanja 0.99 umesto 0.95 (agent više vrednuje buduću odmazdu), eksploracija koja opada do 0.01 umesto trajnog poda od 0.05 (slučajni potezi više ne remete svaku uspostavljenu ravnotežu) i bafer iskustva od 20 hiljada koraka umesto 100 hiljada (procene prate tekuće ponašanje rivala, ne zastarele strategije).

Ishod (slika 13): $\Delta = -0.99 \pm 0.19$, niže i sa većim rasipanjem nego u E1 (-0.77 ± 0.08), bez ijednog ponavljanja iznad Nešove granice, a jednosmerni Mann–Whitney test u pretpostavljenom smeru daje $U = 33$ od 400. Niža vrednost ovde nije neuspeh eksperimenta, nego njegov zaključak: poluge koje bi trebalo da olakšaju dogovaranje u realističnom okruženju nisu proizvele

nikakvu koluziju, već samo nestabilnije učenje. Duži horizont pojačava nestabilnost procena u nestacionarnoj igri, manji bafer daje bućnije gradijente, a slabija eksploracija zaključava agente u lošijim lokalnim optimumima, otuda i rasipanje. Time odsustvo koluzije u E1 prestaje da bude pitanje izbora podešavanja i postaje svojstvo tržišta i budžeta obuke.



Slika 13: Direktno poređenje krivih učenja: E1 (osnovna podešavanja) naspram E6 (podešavanja naklonjena koluziji), prosek preko 20 ponavljanja sa pojasom od jedne standardne devijacije. E6 završava niže i sa širim pojasom; nijedna kriva se ne približava Nešovoj granici.

7 Diskusija

Koluzija nije automatska. U realističnom, podacima kalibrisanom okruženju i uz praktičan budžet obuke, nezavisni D3QN agenti su naučili da formiraju cene dobro, i da se takmiče. Klasični rezultati o algoritamskoj koluziji nastaju posle miliona epizoda tabularne samoigre u stilizovanim tržištima; naš budžet je 1.370 epizoda. Odsustvo koluzije pri realističnim podešavanjima je nalaz sa direktnom regulatornom vrednošću.

Gde se koluzivni profit pojavio, oblik mu je drugačiji nego u literaturi. PPO parovi ne podižu cene sinhronizovano; oni prećutno dele tržište po ulogama. Za regulatore je to suptilniji obrazac od paralelnog rasta cena, jer na nivou pojedinačnih cena ne izgleda kao dogovor. Napominjemo ogradu: demonstriran je koluzivni *ishod* ($\Delta > 0.15$), a ne mehanizam nagrade i kazne u Calvano smislu, jer test prinudne devijacije nije izvođen.

Merenje koluzije je krhko. Ista metrika koja uredno radi na tržištu sa dva heterogena oglasa degenerisala se na bloku identičnih oglasa. Granice ekvilibrijuma vrede onoliko koliko i model potražnje ispod njih, i moraju se eksplicitno proveriti pre interpretacije; ovaj nalaz smatramo metodološki najkorisnijom lekcijom projekta.

Praktična primena. Isti artefakti čine osnovu komercijalnog *pricing engine*-a: model potražnje odgovara na pitanje koja cena maksimizuje očekivani prihod za dati oglas i datum, a istrenirani agent, pušten pohlepno, daje dinamički cenovnik za celu godinu. Za pojedinačnog domaćina je direktna optimizacija nad modelom potražnje ispravniji alat od istreniranog RL agenta: naučena politika je optimalna samo protiv protivnika sa kojima je trenirana, dok pretraga po ceni odgovara na aktuelno stanje tržišta.

8 Ograničenja

- Oznaka rezervacije zadržava deo šuma od blokada domaćina (gornja granica 20 do 25% noći po analizi dužina nizova).
- Cenovni signal je poprečnog preseka; strukturna korekcija vraća relativnu, ali ne i agregatnu elastičnost.
- Model potražnje je zamrznut tokom RL faze; povratna sprema tržišta na nivo potražnje van kanala relativnih cena nije modelovana.
- Budžet od 500,000 koraka je red veličine ispod horizonta konvergencije tabularne literature o koluziji.
- Popunjenost je u granicama fiksirana na istorijskom nivou, dok u simulaciji evoluirala sa rezervacijama; blagi pomeraaj između obuke i simulacije.
- E5 koristi granice bez inflacije, pa se njegov Δ čita kao poređenje sa E1, ne kao apsolutni nivo koluzije.

9 Zaključak

Projekat je izgradio kompletan lanac od sirovih *Inside Airbnb* podataka, preko kalibrisanog modela potražnje sa formalnim kapijama prihvatanja, do višeagentske simulacije sa empirijskim granicama ekvilibrijuma i 120 kompletnih obuka. Centralna hipoteza o spontanoj koluziji DQN agenata nije podržana: agenti uče da se takmiče, ne da se dogovaraju. Nivo koluzije presudno zavisi od izbora algoritma (H2 potvrđena), ali u smeru suprotnom od očekivanja literature, a jedini ishod iznad konkurentskog nivoa (PPO) nastaje prećutnom podelom tržišta, mehanizmom suptilnijim od sinhronizovanog podizanja cena. Pitanje broja agenata (H3) ostaje formalno otvoreno: metrika koluzije se na tržištu sa četiri agenta pokazala neupotrebljivom, a različite normalizacije profita daju suprotne presude, što je samostalna metodološka pouka o merenju. Inflacija nije delovala kao signal za koordinaciju. Dodatna ablacija (E6, 20 ponavljanja) ponovila je E1 sa podešavanjima naklonjenim koluziji (faktor diskontovanja 0.99, eksploracija koja opada do 0.01, kraći bafer iskustva od 20 hiljada koraka): rezultat je $\Delta = -0.99 \pm 0.19$, bez ijednog ponavljanja iznad Nešove granice. Standardne poluge koje u tabularnoj literaturi omogućavaju koluziju ovde je nisu proizvele, čime je zaključak o odsustvu koluzije potvrđen kao svojstvo realističnog tržišta i budžeta obuke, a ne posledica jednog izbora hiperparametara.

Relevantna literatura

- [1] Calvano, E., Calzolari, G., Denicolò, V., Pastorello, S. (2020). *Artificial Intelligence, Algorithms, and Collusion*. American Economic Review, 110(10), 3267–3297.
- [2] Deng, S., Schiffer, M., Bichler, M. (2024). *Algorithmic Collusion in Dynamic Pricing with Deep Reinforcement Learning*. arXiv:2406.02437.
- [3] Tinoco, S., Abeliuk, A., Ruiz-del-Solar, J. (2025). *Impact of Price Inflation on Algorithmic Collusion Through Reinforcement Learning Agents*. arXiv:2504.05335.
- [4] Mnih, V., Kavukcuoglu, K., Silver, D., et al. (2015). *Human-level control through deep reinforcement learning*. Nature, 518(7540), 529–533.
- [5] Sutton, R. S., Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.
- [6] McFadden, D. (1974). *Conditional logit analysis of qualitative choice behavior*. U: Zarembka, P. (ur.), *Frontiers in Econometrics*, 105–142. Academic Press.

- [7] Inside Airbnb. *Get the Data*. <https://insideairbnb.com/get-the-data/> (CC BY 4.0).
- [8] Terry, J., et al. (2021). *PettingZoo: Gym for Multi-Agent Reinforcement Learning*. NeurIPS 34.
- [9] Paszke, A., et al. (2019). *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. NeurIPS 32, 8024–8035.