

Uče li algoritmi da se dogovaraju?

Multi-agent reinforcement learning (DQN) za dinamičku optimizaciju cena na tržištu kratkoročnog iznajmljivanja

Milan Szdov SV21/2023 Lazar Szdov SV25/2023

Kako je nastala ideja

- Na hakatone u Beogradu smo putovali mnogo puta, a smeštaj smo skoro uvek rezervisali preko Airbnb-a.
- Primetili smo da se cene istih stanova stalno menjaju: iz nedelje u nedelju, nekad i iz dana u dan.
- Sve više domaćina cene ne postavlja ručno, nego ih prepušta alatima koji cenu određuju automatski, algoritmima.
- **Pitanje koje nas je povuklo:** šta se dešava kada VIŠE takvih algoritama radi na istom tržištu, jedan protiv drugog?
- Da li nauče da se takmiče, ili nauče da zajedno drže visoke cene, iako se nikada ni o čemu nisu dogovorili?

Šta je prećutno (algoritamsko) dogovaranje

- **Dogovaranje:** konkurenti drže cene iznad konkurentskog nivoa, na štetu kupaca.
- **Prećutno dogovaranje:** isto to, ali bez ijedne poruke i bez tajnog sastanka. Svako gleda tuđe cene i 'shvati' da mu rat cenama ne isplati.
- **Calvano i saradnici (2020):** jednostavni Q-learning agenti u simulaciji sami nauče da drže visoke cene, čak i da kažnjavaju onog ko obori cenu.
- **Zašto je to bitno:** algoritam ne može da potpiše dogovor, pa je ovakvo ponašanje pravno siva zona koju regulatori tek istražuju.
- **Naš cilj:** proveriti da li se to dešava i na realističnom tržištu, naučenom iz stvarnih Airbnb podataka, sa realnim budžetom treninga.

Tri hipoteze

H1

DQN agenti se dogovaraju

Dva nezavisna DQN agenta na istom tržištu dostići će profit iznad konkurentskog nivoa: $\Delta > 0.15$. Ovo je glavna hipoteza projekta.

H2

Nivo dogovaranja zavisi od algoritma

Različiti algoritmi učenja (tabelarni Q, DQN, PPO) daju različit nivo dogovaranja. Literatura očekuje: jednostavniji algoritmi lakše se dogovaraju, dakle TQL iznad DQN iznad PPO.

H3

Manje agenata, više dogovaranja

Sa 2 agenta dogovor je lakši nego sa 4: $\Delta(2 \text{ agenta}) > \Delta(4 \text{ agenta})$. Više konkurenata znači jači podsticaj da se cena obori.

Kako merimo dogovaranje: Indeks dobiti Δ

$$\Delta = (\pi - \pi_N) / (\pi_M - \pi_N)$$

- **π** : profit koji naši agenti stvarno ostvare tokom treninga.
- **π_N (Nash)**: profit u konkurentskoj ravnoteži: stanje u kom niko ne može da zaradi više tako što sam promeni svoju cenu.
- **π_M (monopol)**: profit kada bi jedan vlasnik kontrolisao sve oglase i cene birao zajednički.
- **Skala**: $\Delta = 0$ je konkurentsko tržište, $\Delta = 1$ je pun kartel. Prag za dogovaranje u ovom projektu: $\Delta > 0.15$.
- **Važno**: obe granice računamo empirijski, na istom simuliranom tržištu na kom agenti uče, pa su svi brojevi uporedivi.

Odakle podaci: Inside Airbnb, London


- **Inside Airbnb:** nezavisan projekat koji periodično 'snima' celu Airbnb ponudu po gradovima i objavljuje je javno (CC BY 4.0).
- **Četiri snimka Londona,** uparena u dva sezonska para: maj i jun 2026 (primarni par) i septembar i oktobar 2025 (jesenji par).
- **listings.csv:** 92.638 oglasa sa cenom, tipom smeštaja, kapacitetom, recenzijama i lokacijom (oko 90 kolona).
- **calendar.csv:** oko 33,9 miliona redova po snimku: za svaku noć unapred, da li je slobodna ili zauzeta.
- **reviews.csv:** istorija recenzija; koristimo je da izdvojimo aktivne oglase i proverimo obim rezervacija.

Kako znamo da je noć rezervisana?

- Nigde u podacima ne piše 'rezervisano'. Labelu pravimo poređenjem dva snimka kalendara.
- **Pravilo:** noć koja je bila slobodna u prvom snimku (t_0), a zauzeta u drugom (t_1), brojimo kao rezervisanu unutar prozora od 26 dana.
- **Zašto ne prosto 'zauzeto = rezervisano'?** Zato što domaćini i ručno blokiraju termine. Blokada nije tražnja, i to bi zagadilo model.
- **Zašto ne recenzije?** Recenzije se završavaju na dan snimka, a kalendar tek tada počinje: vremenski se uopšte ne preklapaju. Recenzije zato služe samo kao filter aktivnosti.
- Noći koje su već bile zauzete u t_0 izbacujemo: o njima ne znamo ništa novo.



Filtriranje: od 92.638 do 29.984 oglasa

- **Tip smeštaja:** samo ceo stan i privatna soba; hoteli i deljene sobe su mali i šarolik ostatak.
- **Aktivnost:** bar jedna recenzija u poslednjih 180 dana, inače je kalendar uglavnom šum od blokiranja.
- **Prisutan u oba snimka,** sa cenom u t0: to je cena koja je važila tokom prozora labela.
- **Razumna cena:** od 10 GBP do 99. percentila.
- **Konkurencija:** za svaki oglas tražimo 5 najbližih oglasa istog tipa i sličnog kapaciteta; bez bar 3 konkurenta oglas ispada.
- **Pauzirani oglasi** (ceo kalendar preokrenut) se izbacuju, oko 1%.



Klasteri konkurenata: 5 najbližih oglasa istog tipa, kapacitet ± 1 .


Cene i lokacije



- Cene imaju dugačak desni rep: zato koristimo log-cenu i sečemo na 99. percentilu.
- Westminster ima najviše gusto zbijenih, uporedivih oglasa, pa simulirana tržišta biramo baš tamo.

Koliko je labela pouzdana?



- Uzastopne rezervisane noći čine 'nizove'. Tipičan niz traje 3 noći, kao stvarni boravci gostiju.
- **Nizovi duži od 28 noći** verovatno su blokiranja domaćina: takvih je 20 do 25% rezervisanih noći.
- **Taj šum ne krijemo:** prijavljen je u izveštaju kao granica pouzdanosti labela.
- Bolju labelu ovi podaci jednostavno ne dozvoljavaju; bitno je da znamo koliko joj verujemo.



Raspodela dužina rezervisanih nizova.

Finalni skup podataka

- **7.155.606 noći** sa 29.984 oglasa; stopa rezervacije 13,7% (13,2 letnji par, 14,1 jesenji).
- **20 obeležja po noći**: odnos cene prema konkurenciji, popunjenost, recenzije, kapacitet, sezona, vikend, koliko unapred (lead).
- **Podela 70/15/15 hronološki**: model predviđa budućnost, pa nasumična podela ne dolazi u obzir.
- **Zašto dva sezonska para?** Unutar jednog para datum noći i lead su savršeno vezani (gornja slika): sezona i lead ne mogu da se razdvoje. Drugi par tu vezu razbija.



Dva stuba projekta

- Istorijski podaci ne mogu direktno da treniraju agenta: u njima piše samo šta se desilo sa cenama koje su STVARNO postavljene.
- Agent mora da proba i pogrešne cene i da vidi posledice. Za to mu treba model sveta u kom sme da greši.

STUB 1 · MODEL TRAŽNJE

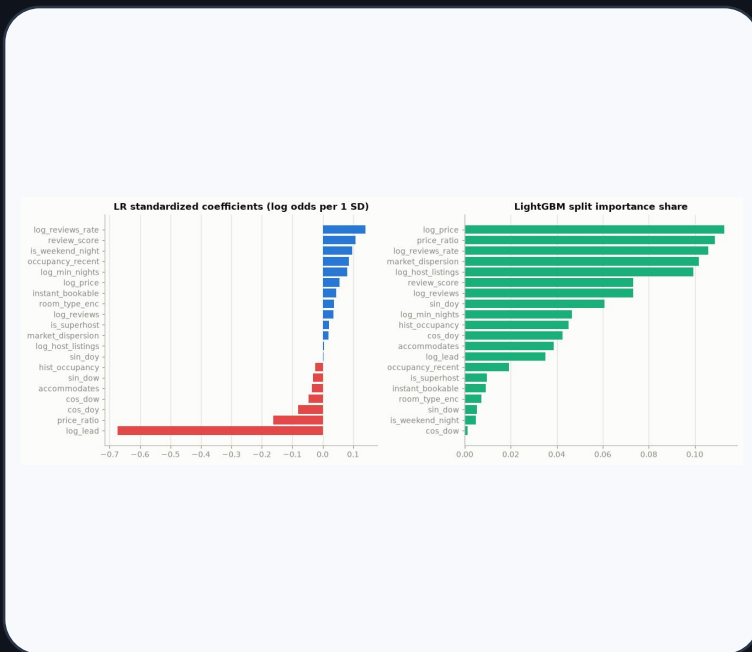
Nadgledano učenje: $P(\text{rezervacija} \mid \text{cena}, \text{kontekst})$ na 7,16 miliona noći. Kada agent postavi cenu, ovaj model kaže kolika je šansa da noć bude rezervisana. On je fizika simulacije.

STUB 2 · SIMULACIJA TRŽIŠTA

Multi-agent okruženje (PettingZoo): svaki agent je jedan stvaran oglas i svake noći bira cenu. Nagrada je ostvaren prihod. Na istoj simulaciji računamo i Nash, monopol i Δ , pa je sve uporedivo.

Stub 1: tri modela, tri uloge


- **Logistička regresija:** osnovna linija i provera smera: koeficijent cene je -0.163 , skuplje znači manje rezervacija, kako i treba.
- **LightGBM (stabla):** dijagnostički plafon. PR-AUC 0.267 pokazuje koliko signala uopšte ima u obeležjima.
- **MLP (neuronska mreža):** primarni model. PR-AUC 0.156, tri puta iznad slučajnog pogađanja (0.048).
- **Zašto MLP ako su stabla jača?** Stabla daju stepenastu reakciju na cenu, a za optimizaciju prihoda treba glatka kriva. Razliku prijavljujemo otvoreno.
- **Bez balansiranja klasa:** simulacija koristi verovatnoće direktno, pa je kalibracija važnija od recall-a. Balansiranje bi verovatnoće iskrivilo.



Šta pokreće predikcije modela.

Kalibracija


- **Kalibrisan model:** kada kaže 20%, otprilike svaka peta takva noć zaista bude rezervisana.
- **ECE 0.0156:** predviđene i stvarne učestalosti razlikuju se u proseku za oko 1,6 procentnih poena. Rekalibracija nije bila potrebna.
- **Ostale metrike na test skupu:** log-loss 0.1795, Brier 0.0437, PR-AUC 0.156.
- **Zašto je ovo presudno:** te verovatnoće su fizika simulacije. Da su sistematski pomerene, pomerili bi se i Nash, i monopol, i svako Δ u projektu.



Kriva pouzdanosti MLP modela na test skupu.

Korekcija elastičnosti: da tržište ima smisla

- **Problem:** skuplji stanovi u podacima su i lepši stanovi. Sirov model zato potcenjuje koliko bi baš taj stan izgubio kada bi digao SVOJU cenu.
- **Simptom:** sirova kriva prihoda raste sve do plafona cene (2.5x medijane), što je ekonomski besmisleno.
- **Rešenje:** $P_{sim}(r) = P(r) \cdot \exp(\beta \cdot (r-1))$, gde je $\beta = -0.425$. Na $r = 1$ korekcija je neutralna, pa kalibracija ostaje netaknuta.
- **β je izabrano** tako da vrh prihoda padne na odnos 1.1: domaćini već cene blizu svog optimuma.
- **Zašto baš eksponencijalni oblik?** Stepena funkcija ne može da da unutrašnji vrh prihoda; eksponencijalna odgovara logit tražnji iz literature.



Kriva tražnje pre i posle korekcije; vrh prihoda na 1.1.

Stub 2: simulacija tržišta

- **Okruženje (PettingZoo):** svaki agent je jedan STVARAN oglas iz Westminstera. Epizoda je jedna godina: 365 noći, svake noći nova cena.
- **Opservacija (7 brojeva):** odnos svoje cene prema rivalima, raspršenost i trend tržišta, sopstvena popunjenost, sezona, vikend.
- **Akcije (5):** promeni cenu za -10%, -5%, 0%, +5% ili +10%.
- **Nagrada:** prihod ako je noć rezervisana, podeljen sopstvenom baznom cenom, da jeftini i skupi oglasi uče na istoj skali.
- **Rivalske cene sa zakašnjenjem od 1 koraka:** svi odlučuju istovremeno, pa 'trenutne' tuđe cene ne postoje. Kao u stvarnosti: gledaš jučerašnje cene konkurencije.
- **Granice cene:** od 0.5x do 2.5x medijane klastera; svaki udar u granicu se beleži.

Granice: Nash, monopol i tri osnovne politike

- **Nash:** iterativni najbolji odgovori dok se niko više ne pomera. Jedan prolaz optimizacije NIJE ravnoteža i potcenio bi Nash profit.
- **Monopol:** maksimizacija ZAJEDNIČKOG profita, kao da sve oglase vodi jedan vlasnik, iz više početnih tačaka.
- **Za tržište sa 2 agenta:** Nash profit 0.4214 (odnosi cena 1.075 i 1.55), monopol 0.4957 (2.5 i 1.125). Oba optimuma su asimetrična!
- **Osnovne politike, ista skala:** drži baznu cenu 0.3153, nasumična 0.2976, prati medijanu 0.2642. Sve ispod Nasha, kako i treba.
- **Ključna činjenica:** najbolji SIMETRIČNI profil cena daje 0.4183, manje od Nash profita. Dva identična agenta koja se kreću zajedno ne mogu ni do Nasha. Ovo kasnije objašnjava negativna Δ .

Agenti 1: DQN, i naš D3QN

- **Q-učenje:** nauči $Q(s, a)$: koliko dugoročno vredi akcija a u stanju s . Politika je onda prosta: uzmi akciju sa najvećim Q .
- **DQN:** umesto tabele, Q računa neuronska mreža, pa slična stanja dele znanje. Dva klasična stabilizatora: replay buffer (100.000 prelaza, nasumični mini-batchevi razbijaju korelaciju uzastopnih noći) i target mreža (zamrznuta kopija za mete, osvežava se na 500 koraka, da mreža ne juri sopstveni rep).
- **Double DQN:** online mreža BIRA najbolju sledeću akciju, target mreža je OCENJUJE. Leči precenjivanje Q vrednosti, koje je u multi-agent okruženju još izraženije.
- **Dueling:** mreža odvojeno uči vrednost stanja $V(s)$ i prednosti akcija $A(s, a)$. Korisno kada susedne cene vrede skoro isto, a stanje nosi većinu vrednosti. Zajedno: D3QN.
- **Topli start:** mreže prvo kloniraju 'sidrišnu' politiku (vraćaj cenu ka izlistanoj baznoj), jedino ponašanje domaćina koje podaci stvarno sadrže. Bez toga se stotine epizoda troše na nasumične cene.

Agenti 2: PPO

- **Druga filozofija:** umesto Q vrednosti, PPO direktno uči POLITIKU: raspodelu verovatnoća preko 5 akcija. Akcija se IZVLAČI iz raspodele, ne bira se uvek najbolja.
- **Actor-critic:** glumac (politika) i kritičar (procena vrednosti stanja) dele jednu mrežu; kritičar smanjuje šum učenja.
- **'Proximal':** svaka izmena politike je ograničena (clip 0.2): mali sigurni koraci umesto velikih skokova.
- **On-policy:** uči isključivo iz sveže sopstvene igre (2048 koraka), pa prati TRENUTNO ponašanje rivala. DQN nasuprot tome replayom uči i iz zastarelog iskustva.
- **Naša implementacija:** oko 200 linija, bez gotovih biblioteka, da svi agenti dele isti kod okruženja i logovanja.



Kriva učenja PPO agenata (E3).

Agenti 3: tabelarno Q-učenje, most ka literaturi

- **Isti algoritam kao kod Calvana (2020):** Q vrednosti u doslovnoj tabeli, ažuriranje posle svakog koraka.
- **Diskretizacija:** kontinualno stanje se grubo deli na kutije: $8 \cdot 4 \cdot 4 \cdot 4 \cdot 6 \cdot 2 = 6.144$ stanja puta 5 akcija.
- **Problem:** svaka ćelija tabele mora da se poseti mnogo puta. Kod Calvana: milioni epizoda na malom svetu. Kod nas: 1.370 epizoda na pravom tržištu.
- **Uloga u projektu:** nije primarni metod, nego poređenje: šta algoritam iz literature stvarno uradi u realističnom okruženju sa realnim budžetom.



Kriva učenja tabelarnog Q agenta (E4).

Šest eksperimenata, 120 treninga

Eksp.	Postavka	Na šta odgovara
E1	D3QN, 2 agenta	Glavna proba dogovaranja (H1)
E2	D3QN, 4 agenta	Uticaj broja agenata (H3)
E3	PPO, 2 agenta	Zavisnost od algoritma (H2)
E4	Tabelarni Q, 2 agenta	Most ka literaturi (H2)
E5	D3QN + inflacija 10% godišnje	Da li zajednički šok sinhronizuje agente
E6	D3QN, podešavanja naklonjena dogovaranju	Robusnost zaključka H1

- Svaki eksperiment: 20 nezavisnih seed-ova puta 500.000 koraka, što je 1.370 simuliranih godina po treningu.
- Nezavisno multi-agent učenje je nestabilno po prirodi, pa sve tvrdimo preko raspodela, nikad iz jednog treninga.

Δ po eksperimentu: raspodele preko 20 seed-ova



Eksp.	Δ (std)
E1 DQN, 2 ag.	-0.77 (0.08)
E2 DQN, 4 ag.	-1.23 (0.17)
E3 PPO, 2 ag.	+0.27 (0.13)
E4 TQL, 2 ag.	-1.26 (0.22)
E5 inflacija	-1.00 (0.08)
E6 ablacija	-0.99 (0.19)

Samo PPO (E3) prelazi konkurentski nivo i prag 0.15.

H1: DQN se ne dogovara

NIJE PODRŽANA

- **Test:** jednostrani t-test protiv praga 0.15: $t = -51.7$, $p = 1.0$.
- **Agenti uče dobro:** 15,6% iznad sidrišne politike, 22,4% iznad nasumične, 37,9% iznad praćenja medijane.
- **Ali:** cene drže blizu medijane tržišta (odnos 1.11) i zarađuju ISPOD Nash profita.
- **To nije neuspeh učenja:** ravnoteže ovog tržišta su asimetrične, a najbolji simetrični profil je ispod Nasha. Identični agenti tu prosto ne mogu.
- **Poruka:** na realističnom tržištu, sa praktičnim budžetom, dogovaranje NIJE automatska pojava. Klasični rezultati nastaju posle miliona epizoda u stilizovanim svetovima.



Kriva učenja E1: profit raste, pa se stabilizuje ispod Nasha.

H2: algoritam je presudan, redosled obrnut

PODRŽANA

- **Test:** Kruskal-Wallis preko tri algoritma: $H = 51.2$, $p = 7.7e-12$. Algoritam presudno utiče na ishod.
- **Obrt:** literatura očekuje $TQL > DQN > PPO$. Mi dobijamo $PPO > DQN > TQL$, sa skoro savršenim razdvajanjem grupa.
- **PPO (E3) dostiže $\Delta = +0.27$** , jedini iznad praga. Mehanizam je prećutna PODELA TRŽIŠTA: jedan agent drži plafon cene, drugi ga podseca i kruži ispod (Edgeworth obrazac), po ugledu na asimetrični monopolski optimum.
- **Kontrolna proba:** kada politiku nasilno učinimo striktno pohlepnom, Δ pada na -0.15 . To POTVRĐUJE mehanizam: nasumičnost politike sama održava podelu tržišta.




Putanje cena E3: jedan agent gore, drugi kruži ispod.

H3: bez zaključka, i zašto je to pošten odgovor

BEZ ZAKLJUČKA


- **Formalni test ide u prilog hipotezi** ($p = 3.9e-08$), ali ga ne proglašavamo dokazom.
- **Granice za 4 agenta su degenerisane:** četiri skoro identična stana zajedničkim dizanjem cena gotovo ništa ne gube, pa Nash završava na plafonu cene (0.883; monopol 0.995).
- **Tamo Δ ne meri dogovaranje:** agenti na 1.84x medijane dobijaju $\Delta = -1.23$ po konstrukciji.
- **Dokaz da metrika ne postoji:** profit kao udeo Nasha favorizuje E1 ($p = 0.002$), a kao udeo monopola favorizuje E2 ($p = 0.986$). Suprotne presude iz istih brojeva.
- **Kvalitativno:** četiri agenta se ne koordinišu (kolektivni rat cenama sredinom godine). U duhu hipoteze, ali ostaje zapažanje, ne dokaz.



Putanje cena E2: labavo krdo i rat cenama, bez koordinacije.

Provere robusnosti: inflacija (E5) i ablacija (E6)


- **E5, inflacija 10% godišnje:** ponašanje isto kao E1 na istim relativnim cenama; nominalne cene samo gube realnu vrednost ($\Delta = -1.00$). Zajednički šok NE sinhronizuje agente.
- **E6, ablacija:** tri poluge koje u literaturi pomažu dogovaranju: strpljeniji agenti ($\gamma = 0.99$), manje istraživanja (ϵ do 0.01), mali buffer (20.000) da mete prate trenutnog rivala.
- **Rezultat:** $\Delta = -0.99$, nijedan seed iznad Nasha. Učenje postane nestabilnije, ne koluzivnije.
- **Čemu služi:** zatvara najverovatniji prigovor. Odsustvo dogovaranja je osobina tržišta i budžeta, a ne naših hiperparametara.



E1 i E6 krive učenja: ista priča, više nestabilnosti.

Šta smo naučili

- **Dogovaranje nije automatska pojava:** realistično tržište plus praktičan budžet daju konkurentno ponašanje DQN agenata.
- **Izbor algoritma je presudan,** i to u neočekivanom smeru: moderni PPO, a ne 'naivni' tabelarni Q, nalazi profit iznad konkurentskog, kroz podelu tržišta.
- **Merenje dogovaranja je teško:** bez valjanih granica Δ ume da laže, što smo pokazali na 4-agentskom tržištu.
- **Mogući pravci istraživanja:** strategije kažnjavanja kao kod Calvana, tržišna (a ne samo relativna) elastičnost, drugi gradovi, duži budžeti treninga, mešoviti algoritmi na istom tržištu.



Zajedničke akcije E1: bez obrasca kažnjavanja.

Budući razvoj

- **Drugi grad ili kvart:** ponoviti studiju na npr. Camden tržištu i proveriti da li zaključci važe van Westminstera.
- **Duži budžeti treninga:** približiti se horizontu na kom literatura vidi dogovaranje i videti kada se (i da li se) slika menja.
- **Povratna sprega tražnje:** da zajedničko dizanje cena smanjuje ukupnu tražnju, ne samo preraspodelu među rivalima.
- **Mešovita tržišta:** DQN protiv PPO na istom tržištu, heterogeni oglasi, više agenata sa zdravim granicama.
- **Praktična strana:** trenirani agent kao savetnik za cenu konkretnog oglasa (demo već postoji u svesci 04).

Hvala na pažnji!

Pitanja?